

# ReSTIR PT Enhanced: 面向更快、更稳健 ReSTIR 路径追踪的算法进展——中文精翻

原文: ReSTIR PT Enhanced: Algorithmic Advances for Faster and More Robust ReSTIR Path Tracing  
作者: Daqi Lin、Markus Kettunen、Chris Wyman (NVIDIA) 出处: PACM CGIT 9(1), Article 13, 2026 年 5 月, 19 页 DOI: 10.1145/3804494 许可: Creative Commons Attribution 4.0 International (CC BY 4.0)

■ 译注: 本稿按原文章节、公式编号、图表编号与脚注顺序翻译。原文没有伪代码或代码块。页眉、页脚和重复出版信息不逐页复写。参考文献保留可检索的英文题名, 并补充中文释义。 $p_{\text{hat}}$  始终指未归一化目标函数,  $p/p_{\text{bar}}$  指概率密度,  $m(i)$  指重采样 MIS 权重,  $\omega(t)$  指路径采样技术 MIS 权重; reservoir 的样本、贡献权重与置信权重分别写作  $X$ 、 $W_X$ 、 $c$ , 不把它们混同为工程实现常见的  $W/M$ 。

## 摘要

近年来, 利用 ReSTIR 式时空复用的算法大量涌现, 它们显著提高了实时光线追踪器和路径追踪器中光传输的有效样本数。许多论文研究了新的理论改进, 但对于获得最优实现所需的算法改良与工程经验, 关注仍然不足。本文给出一组针对 ReSTIR PT 的增强方法: 使其速度提高 2 - 3 倍, 同时降低视觉误差和数值误差并提升稳健性, 让它更接近可用于产品的状态。

我们通过互惠邻居选择 (reciprocal neighbor selection) 把空间复用成本减半; 以新的、基于足迹 (footprint) 的重连接判据提高移位映射 (shift mapping) 的稳健性; 并用重复图 (duplication map) 降低时空相关性。我们还通过广泛优化、把直接光照与全局光照统一进同一组 reservoir, 以及采用已有的色彩噪声和去遮挡噪声抑制技术, 进一步同时改善性能与质量。

CCS 概念: 计算方法 → 光线追踪。附加关键词: 优化、采样、光传输、实时。

ACM 引用格式: Daqi Lin, Markus Kettunen, and Chris Wyman. 2026. ReSTIR PT Enhanced: Algorithmic Advances for Faster and More Robust ReSTIR Path Tracing. Proc. ACM Comput. Graph. Interact. Tech. 9, 1, Article 13 (May 2026), 19 pages. <https://doi.org/10.1145/3804494>

图 1。我们用一组新算法增强 ReSTIR PT [Lin et al. 2022] 的性能与稳健性。在 Spaceship 场景中, 这些技术带来显著加速, 减少相关性伪影 (第一排局部图) 和色彩噪声 (第三排局部图), 并改善光泽反射 (例如地面) 与折射 (第二排局部图) 的质量。原始 ReSTIR PT: 37.1 ms, FLIP 0.321; ReSTIR PT Enhanced: 12.6 ms, FLIP 0.263。

## 1 引言

ReSTIR Path Tracing [Lin et al. 2022]

通过在时空上复用路径样本, 大幅提升路径质量。但是, 该原型具有很高的计算与内存开销, 即使在高端 GPU 上也相当缓慢; 最初在 RTX 3090 上每帧需要 40 - 80 ms。

按原论文发表时的形态, ReSTIR PT

还存在稳健性问题: 它会遭受时空相关、去遮挡区域附近的方差, 以及色彩噪声。使 ReSTIR PT 能够处理镜面光传输的混合移位 (hybrid shift), 依赖简单的粗糙度阈值和距离阈值来决定复用策略, 而这些阈值往往需要逐场景调整。后续研究提出了部分解决方案 [Kettunen et al. 2023; Sawhney et

al. 2024; Zhang et al. 2024], 但并未解决性能不佳的问题。本文提出的技术显著优化 ReSTIR PT 的性能, 同时改善稳健性和质量, 从而缩小它与产品化之间的差距。

本文的具体贡献包括:

- 通过互惠邻居选择, 把空间复用中的移位映射成本减半\* (第 3 节);
- 提出能够适应场景和材质的新射线足迹阈值\* (第 4 节);
- 通过样本重复图减少相关性伪影\* (第 5 节);
- 把直接光与间接光统一到 ReSTIR 中, 从而改善质量并降低成本 (第 6 节);
- 通过其他优化提升性能与稳健性, 减少色彩噪声和去遮挡噪声 (第 6 节)。

■ \*带星号的贡献也适用于其他时空复用算法, 例如 Bauszat et al. [2017] 和 Ouyang et al. [2021]。

## 2 背景

SVGF [Schied et al. 2017]、NVIDIA NRD [NVIDIA 2020]、DLSS Ray Reconstruction [NVIDIA 2025] 等硬件与去噪方面的进展, 使实时光线追踪全局光照 (global illumination, GI) 变得可行。当今许多实时方案依赖类似辐射度法的递归收集, 并配合离散化、缓存与插值, 例如 Lumen [Wright et al. 2022]、DDGI [Majercik et al. 2019] 和 Surfel GI [Halen et al. 2021]; 这会限制精度与响应速度。暴力路径追踪虽然精确, 却很慢, 需要很多样本才能产生可去噪的图像。

较新的时空 reservoir 重采样 (spatiotemporal reservoir resampling, ReSTIR) [Bitterli et al. 2020], 以无偏方式积极复用其他像素和其他帧的 Monte Carlo 样本。当把它用于路径样本时, ReSTIR 会把追踪路径的成本摊销到空间和时间上。它保留了路径追踪的精度, 却能在相同成本下提供数十乃至数百倍的有效样本。ReSTIR DI [Bitterli et al. 2020] 实现实时多光源渲染; ReSTIR GI [Ouyang et al. 2021] 面向漫反射与中等光泽表面。本文加速 ReSTIR PT [Lin et al. 2022] 并提高其稳健性, 从而改进一般路径的无偏渲染, 包括多次反弹镜面反射和焦散。下面回顾这些 ReSTIR 算法背后的重采样理论。

### 2.1 RIS 与 GRIS

重采样重要性采样 (resampled importance sampling, RIS) [Talbot et al. 2005] 的目标, 是从低方差目标 PDF  $p_{\text{bar}} \propto p_{\text{hat}} \approx f$  中采样, 以估计积分  $\int \Omega f(x) dx$ 。由于通常难以直接从  $p_{\text{bar}}$  采样, RIS 会从一个并非最优的源 PDF  $p$  中抽取  $M$  个独立同分布候选  $X_{(i)} \sim p$ , 再按重采样权重  $w_{(i)} = (1/M) p_{\text{hat}}(X_{(i)})/p(X_{(i)})$  的比例选择一个  $Y$ 。当  $M \rightarrow \infty$  时,  $Y$  的分布收敛到  $p_{\text{bar}} = p_{\text{hat}} / \int \Omega p_{\text{hat}}(x) dx$ 。Talbot et al. [2005] 在构造  $p_{\text{hat}}$  时去掉直接光照中的可见性项, 以提高采样效率。

表达式  $f(Y) W_Y$  是积分  $\int \Omega f(x) dx$  的无偏估计, 其中 (这里每个  $w_i$  已含  $1/M$ ):

$$W_Y = \frac{1}{\hat{p}(Y)} \sum_{i=1}^M w_i$$

$W_Y$  估计的是  $1/p_Y(Y)$ , 即  $Y$  的未知 PDF 的倒数。

广义重采样重要性采样 (generalized resampled importance sampling, GRIS) [Lin et al. 2022] 允许把像  $Y$  这样的随机变量继续用作下一次重采样的候选。这种链式重采样构成了 ReSTIR 的基础。在

GRIS 中，候选样本可以具有不同分布、来自不同定义域  $\Omega_{(i)}$ ，也可以彼此相关。先用双射移位映射  $T_{(i)}: \Omega_{(i)} \rightarrow \Omega$  把样本映射到目标定义域，得到  $Y_{(i)} = T_{(i)}(X_{(i)})$ ；然后使用以下重采样权重：

$$w_i = m_i(Y_i) \hat{p}(Y_i) W_{X_i} \left| \frac{\partial T_i}{\partial X_i} \right| \quad (1)$$

输出  $Y$  按  $w_{(i)}$  的比例抽样。这里， $W_{X_{(i)}}$  是无偏贡献权重：它们是满足  $E[W_{X_{(i)}} | X_{(i)}] = 1/p_{X_{(i)}}(X_{(i)})$  的随机变量，通常来自此前的 RIS 或 GRIS pass； $|dT_{(i)}/dX_{(i)}|$  是移位映射的 Jacobian 行列式； $m_{(i)}$  是重采样 MIS 权重，用来归一化各定义域/技术对目标定义域的覆盖。当  $\text{Var}[\sum_{i=1}^M w_{(i)}] \rightarrow 0$  时，输出分布收敛到  $p_{\text{bar}}$ 。为了保证使用  $Y$  对  $f$  作无偏积分，通常要让 GRIS 的输入中包含一个规范样本（canonical sample），且该样本完整覆盖  $p_{\text{hat}}$  的支撑集。

## 2.2 ReSTIR

基于 reservoir 的时空重要性重采样（ReSTIR）跨帧应用链式 GRIS pass，逐步改善样本分布，从而显著提升实时图像质量。每个像素维护一个 reservoir，本质上是三元组  $(X, W_X, c)$ ：它携带一个样本、该样本的无偏贡献权重，以及一个用于计算重采样 MIS 时衡量定义域/技术的置信权重  $c$ ；后者在原文中称作“有效样本数”。在一次 GRIS pass 中，当前像素的 reservoir 提供规范样本，其他像素则贡献邻居样本。随后把 reservoir 更新为选中的输出样本  $Y$ ，并把所有输入样本的置信权重累加到输出中。

一个 ReSTIR 帧首先为每个像素生成初始候选，并通过 RIS 选出初始样本  $Y$ 。高效流式实现使用加权 reservoir sampling [Chao 1982]，并以  $c = 1$  初始化 reservoir。之后执行时间复用和空间复用；这两者都是把邻居样本纳入候选的 GRIS pass。最后用估计量  $f(X)W_X$  对当前帧着色，并把这些 reservoir 传给下一帧，作为时间邻居。

时间复用。时间 GRIS 通过跟随着色点运动的时间重投影确定邻居。时间 reservoir 的置信权重  $c_{\text{temp}}$  会受置信上限  $c_{\text{Cap}}$  限制；重采样后的新置信度为  $\min(c_{\text{Cap}}, c_{\text{temp}}) + 1$ 。这既避免动态场景中样本更替过慢，也避免相关性无限累积。

空间复用。空间 GRIS 从固定半径的圆盘内随机抽取  $M - 1$  个空间邻居，常用半径为 30 像素。若邻居的 G-Buffer 属性（如法线、深度）差异过大，则拒绝该邻居。空间复用后，置信权重等于所有被接受邻居的置信权重之和。

## 2.3 ReSTIR PT

ReSTIR PT [Lin et al. 2022] 的目标，是复用路径追踪器产生的所有类型路径。对于长度为  $d$  的路径  $\bar{x} = [x_{(0)}, x_{(1)}, x_{(2)}, \dots, x_{(d)}]$ ，ReSTIR GI [Ouyang et al. 2021] 使用与 ReSTIR DI [Bitterli et al. 2020] 相同的重连接移位，复用  $x_{(2)}$  及其后顶点；但当  $x_{(1)}$  或  $x_{(2)}$  为镜面顶点时，这种做法会失效。ReSTIR PT 引入混合移位：把重连接推迟到顶点满足特定重连接判据之后；在此之前，新路径通过复用相同随机数来追踪。ReSTIR PT 在每个顶点只评估一个 BSDF lobes，因此可以分别移位到各个 BSDF lobe；为简洁起见，本文略去 lobe 索引，细节见补充材料。

路径空间定义。路径空间积分  $\sum_{d=1}^{\infty} \int_{\Omega_d} f(\bar{x}) d\bar{x}$  覆盖所有长度的路径，其中  $f(\bar{x})$  包含 BSDF、几何、传感器和发光体项。从首个主表面命中  $x_{(1)}$  开始，路径追踪器在每个顶点为路径延续方向采样 BSDF，同时每个顶点执行下一事件估计（next event

estimation, NEE)。为了在这两种情况下使用不同的移位映射, ReSTIR PT 给  $\bar{x}$  附加一个技术索引, 指出最终路径顶点是由 NEE 采样还是由 BSDF 采样的延续射线得到; 这要求拆分被积函数并使用 MIS 权重。

混合移位。为把路径  $\bar{x}$  移位到  $\bar{y} = T(\bar{x})$ , 早期梯度域渲染工作 (例如 Kettunen et al. [2015]) 要求重连接顶点  $x_k$ 、其前一顶点  $x_{k-1}$  以及  $y_{k-1}$  都是“粗糙”的。为了避免存储基准路径顶点或重放基准路径, ReSTIR PT 在  $\bar{x}$  上预先计算重连接顶点  $x_k$ : 寻找第一个满足两项重连接条件的顶点对  $(x_{k-1}, x_k)$ , 即粗糙度阈值

$$\min(\alpha_{x_{k-1}}, \alpha_{x_k}) \geq \alpha_{\min}$$

( $\alpha$  来自路径采样的 lobe) 以及距离阈值  $\|\bar{x}_k - \bar{x}_{k-1}\| \geq d_{\min}$ , 后者避免几何奇异性。这样可预先决定重放的路径长度并支持 GPU 优化。从  $y_{k-1}$  连接到  $x_k$  时, 还要检查移位是否可逆。

Jacobian。ReSTIR PT 的实现通常采用主样本空间 (primary sample space, PSS) 参数化。给定路径长度  $d$  和采样技术  $t$ , 路径追踪器把随机数序列  $\bar{u}$  转换成路径。记生成的路径为  $\bar{x} = X_{t,d}(\bar{u})$ , 则我们在单位超立方体上积分

$$F(\bar{u}) = \frac{\omega_t(\bar{x}) f(\bar{x})}{p_t(\bar{x})}$$

其中  $\omega_t$  是在不同技术之间划分路径空间的 MIS 权重,  $p_t(\bar{x})$  是路径空间 PDF。假设  $\bar{u}$  与  $\bar{x}$  关联, 且  $T(\bar{u})$  把它映射到与  $\bar{y}$  关联的序列; 用上标  $x, y$  表示与两条路径有关的量。混合移位的 PSS Jacobian 行列式为:

$$\left| \frac{\partial T}{\partial \bar{u}} \right| = \frac{p_{k-1}^y(\omega'_{k-1}) G(y_{k-1} \rightarrow x_k) p_k^y(\omega_k)}{p_{k-1}^x(\omega_{k-1}) G(x_{k-1} \rightarrow x_k) p_k^x(\omega_k)} \quad (2)$$

它对应于从  $y_{k-1}$  重连接到  $x_k$ ; 若不发生重连接, Jacobian 为 1。这里  $\hat{p}(x)_k(\omega_k) \equiv p(\omega_k | x_k, -\omega_{k-1})$  是方向  $-\omega_{k-1}$  条件下采样方向  $\omega_k$  的立体角 PDF; 当  $k=d$  时以 1 替代  $\hat{p}(x)_k(\omega_k)$ ;  $\omega'_{k-1}$  是  $y_{k-1} \rightarrow x_k$  的简写。单侧几何项  $G(x \rightarrow y) = \cos \theta / \|x-y\|^2$ , 其中  $\theta$  是  $y_{k-1} \rightarrow x_k$  与  $y_{k-1}$  法线的夹角。

实现。ReSTIR PT 假设已经存在直接光照 (DI) 采样方法, 并在自己的估计量中跳过 DI 路径 [Lin et al. 2022]。初始重采样阶段, 路径追踪器生成路径树, 随后通过 RIS 从间接光路径中选出一条代表性路径。为了支持时间和空间复用, reservoir 中保存关联随机种子、重连接顶点  $x_k$ , 以及  $x_k$  处的入射辐射亮度和方向, 以便执行移位映射。

本文的 ReSTIR PT Enhanced 保留基线架构 [Lin et al. 2022], 同时通过邻居配对 (第 3 节) 把空间复用成本减半, 引入与场景无关的重连接判据 (第 4 节), 通过自适应降低  $c_{\text{Cap}}$  实现样本去相关 (第 5 节), 并包含多项提升性能的优化 (第 6 节)。

### 3 更高效的配对空间复用

ReSTIR PT 的空间和时间复用依赖 GRIS

重采样。邻居复用不仅要求把邻居移位到当前像素，还要求把当前像素移位到邻居，以便计算正确的 MIS 权重。即使使用高效的成对 MIS [Lin et al.

2022]，所有空间邻居仍需要两次移位，从而使工作量翻倍（图 2 左）。

如果像素 A 从 B 复用，就必须把两个像素的路径分别移位到对方。我们观察到：A 从 B 复用之后，B 可以免费地从 A 复用，因为重复的空间移位已经完成。因此可以摊销重复移位，节省 50% 成本（图 2 右）。为高效配对像素 A 和 B，我们预先计算随机复用纹理，为每个像素存储其耦合邻居的坐标偏移：A 存储指向 B 的差值，B 存储指向 A 的差值。若要从多个邻居复用，则准备多张相互独立的纹理。

#### 3.1 计算复用纹理

要在全局约束下生成具有给定距离分布的坐标差复用纹理，并非易事；我们发现基于优化的方法慢且不可靠。于是，我们通过随机打乱来置换初始纹理；由这些随机游走产生的偏移服从正态分布。

假设目标标准差  $\sigma \geq 0.8$  像素<sup>(1)</sup>。选择一个偶数、类似图像尺寸的正方形，例如  $254 \times 254$ ，并用连续的连接索引填充它（图 3 左）。随后用  $n_\sigma$  次平铺的  $2 \times 2$  洗牌打乱连接索引，每隔一次在绕过边缘时把偏移量设为 1（图 3 右）。重复次数为：

$$n_\sigma = \left\lfloor \frac{\sigma^2}{2} + 1.46\sigma^{-1} + 1.76\sigma^{-2} + 0.656\sigma^{-3} + 0.5 \right\rfloor$$
$$\approx \left\lfloor \frac{\sigma^2}{2} + 0.5 \right\rfloor \quad (3)$$

重复洗牌使每个链接索引近似按标准差  $\sigma/\sqrt{2}$  的正态分布移动。随后把具有匹配链接索引的像素配对。由于每次洗牌都会降低相关性，坐标差近似服从标准差为

$$\sqrt{\frac{\sigma^2}{2} + \frac{\sigma^2}{2}} = \sigma$$

的正态分布。式（3）中的负次幂是针对小  $\sigma$  的拟合修正。

<sup>(1)</sup> 支持的最小  $\sigma$  为 0.8，这是进行一次洗牌迭代得到的值。<sup>(2)</sup>  $256 \times 256$  分辨率需要 16 位通道，才能表示 128、-128 以及更大的坐标差。

#### 3.2 使用复用纹理

链接位于复用纹理内部，靠近边缘的链接可能跨越纹理边界。为了使复用纹理可平铺，我们断开长链接：若坐标差大于纹理宽度的一半，就减去正方形纹理的宽度；若坐标差小于负的半宽度，就加上纹理宽度。最后把  $x$ 、 $y$  两个方向的差值打包到 16 位亮度纹理中。

查找链接。为找到坐标差，每个像素要定位与自己具有相同链接索引的另一个像素。CUDA

实现构造大小为  $N/2 \times 2$  的索引表，其中  $N$

是复用纹理的像素数。首先，每个像素读取自身链接索引，并把像素位置写入索引表的  $(linkIndex, 0)$ 。这是一次带数据竞争的并行写入，因此只有一半像素会成功。随后，位置不在  $(linkIndex, 0)$  的像素把自己写入  $(linkIndex, 1)$ 。这样每个像素都能在索引表中找到配对邻居。

假设空间复用使用  $N$  个邻居，我们预加载  $N$

张复用纹理。为避免纹理重复带来的相关性伪影，每张纹理选择不同尺寸，例如三个邻居分别使用 254、230、210<sup>^</sup>(3)。复用纹理是自逆的：A 链接到 B，同时 B 链接到 A，因此复用纹理应逐帧变化。我们不生成很多纹理，而是在每一帧随机翻转、镜像、转置和偏移每张复用纹理；经验上这已经完全解决重复问题。

<sup>^</sup>(3) 启发式算法试图把 3840 像素范围内的近周期降到最低；所谓近周期，是某张纹理宽度的整数倍接近另一张纹理宽度整数倍的情况。

### 3.3 讨论

Bekaert et al. [2002] 把  $16 \times 16$  像素块拆成 16 像素的 N-rook

模式，并在每组内部执行全连接复用。这同样避免了计算 MIS 权重的额外工作，但在样本数较低时会产生结构化伪影。我们叠加多张尺寸不同、经高斯置换的复用纹理，避免这种结构；每个像素遵循不同的随机复用模式，不存在块边界。我们的复用纹理也可用于经典路径复用。

## 4 与场景无关的重连接判据

在 ReSTIR

样本复用期间，邻居样本会先移位到当前定义域，再参与复用。理想的移位映射应保持路径的目标 PDF 值，即

$$\bar{p}_j(T(\bar{u})) \left| \frac{\partial T}{\partial \bar{u}} \right| \approx \bar{p}_i(\bar{u})$$

不失一般性，本文假设  $\bar{p}_{\text{bar}_j}(T(\bar{u}_{\text{bar}})) \approx \bar{p}_{\text{bar}_i}(\bar{u}_{\text{bar}})$ <sup>^</sup>(4)，重点分析 ReSTIR PT 混合移位中如何选择重连接顶点，使  $|dT/du_{\text{bar}}| \approx 1$ 。优良的移位映射应该满足这一条件。

原始混合移位 [Lin et al. 2022] 使用距离阈值  $||x_k - x_{\{k-1\}}|| \geq d_{\text{min}}$

禁止短路径重连接（例如拐角附近），并使用粗糙度阈值  $\min(\alpha_{\{x_{\{k-1\}}\}}, \alpha_{\{x_k\}}) \geq \alpha_{\text{min}}$  禁止在高度光泽表面上连接。这些阈值可能不是最优的，而且适合的重连接距离和粗糙度水平往往相互依赖，需要逐场景调参。

我们提出双重射线足迹阈值和新的单顶点粗糙度阈值，在存在镜面材质时提供更稳健的重连接约束，不需要场景专用调参，并能更早（因而更便宜）地获得重连接机会。

新足迹阈值的直觉来自  $|dT/du_{\text{bar}}| \approx 1$  的几何含义。首先把它写成两个比值的乘积：

$$\frac{p_{k-1}^y(\omega'_{k-1}) G(y_{k-1} \rightarrow x_k)}{p_{k-1}^x(\omega_{k-1}) G(x_{k-1} \rightarrow x_k)} \quad (4a)$$

$$\frac{p_k^y(\omega_k)}{p_k^x(\omega_k)} \quad (4b)$$

第一项比较顶点  $x_k$  在假设从  $y_{\{k-1\}}$  追踪和原本从  $x_{\{k-1\}}$

追踪时的面积密度；第二项比较在不过方向  $y_{\{k-1\}} \rightarrow x_k$  的假设下采样  $\omega_k$

的立体角密度，与原本不过方向  $x_{\{k-1\}} \rightarrow x_k$  时的密度。我们的阈值试图限制这些密度的变化。

表面顶点面积概率密度的倒数，在几何上就是足迹，即该样本所代表的面积。直观地说，更长的重连接距离或  $x_{[k-1]}$  处更粗糙的材质，会扩大射线足迹并减少移位映射中的密度变化，因此从  $x_{[k-1]}$  重连接更有价值。为了约束式（4b），我们考察逆射线足迹

$$[p_k^x(\omega_k) G(x_k \rightarrow x_{k-1})]^{-1}$$

它是从  $x_k$  追踪产生  $x_{[k-1]}$

时的倒数面积密度。我们的分析表明，对此足迹设阈值等价于约束式（4b）中的立体角密度变化。

具体地，新的重连接判据定义为双重射线足迹阈值：

$$\min([p_{k-1}^x(\omega_{k-1}) G(x_{k-1} \rightarrow x_k)]^{-1}, [p_k^x(\omega_k) G(x_k \rightarrow x_{k-1})]^{-1}) \geq \frac{c}{100} \frac{|x_0 - x_1|^2}{\langle n_{x_1}, \hat{x}_{1x_0} \rangle / (4\pi)} \quad (5)$$

式右侧是主射线足迹的常数倍，用来度量相邻主命中点之间的距离。我们发现常数乘子  $c = 0.02$ （即  $c/100 = 0.0002$ ）在多种场景中表现良好。除此之外，还在  $x_{[k-1]}$  顶点强制施加单顶点阈值  $\alpha_{\{x_{[k-1]}\}} \geq \alpha_{\min}$ ，以低成本避开某些棘手边界情况。

^(4) 在  $\omega_t(x_{\text{bar}}) f(x_{\text{bar}}) / p_t(x_{\text{bar}})$  中，几何项和微表面 NDF 项会相互抵消，从而避免移位时出现极端值。

#### 4.1 双足迹阈值的解释

下面简要解释双足迹阈值如何实现边界约束；完整推导见补充材料。考虑把路径  $x_{\text{bar}}$  在一个像素内移位到另一个像素，记  $y_{\text{bar}} = T(x_{\text{bar}})$ 。对于  $x_{\text{bar}}$  上的候选重连接顶点  $x_k$ ，从  $y_{[k-1]}$  而不是  $x_{[k-1]}$  连接，会扰动  $x_k$  的路径追踪面积密度和  $\omega_k$  的角密度。我们希望相对变化足够小：对小  $\varepsilon$ ，

$$\left| \frac{p_{k-1}^y(\omega'_{k-1}) G(y_{k-1} \rightarrow x_k)}{p_{k-1}^x(\omega_{k-1}) G(x_{k-1} \rightarrow x_k)} - 1 \right| < \varepsilon \quad (6a)$$

$$\left| \frac{p_k^y(\omega_k)}{p_k^x(\omega_k)} - 1 \right| < \varepsilon \quad (6b)$$

这两个条件意味着  $(1 - \varepsilon)^{(2)} < |dT/du_{\text{bar}}| < (1 + \varepsilon)^{(2)}$ 。

射线足迹阈值。式（6a）要求约束从  $y_{[k-1]}$  而不是  $x_{[k-1]}$  重连接时  $x_k$  的面积密度变化。假定随机重放保持局部面积密度（图 4），我们分析在空间位移  $\Delta x_k = y_k - x_k$  下  $x_k$  面积密度的变化，其中  $y_k$  由从  $y_{[k-1]}$  重放得到。

假设  $||\Delta x_k||$  被主射线足迹的常数倍限制：

$$|\Delta \mathbf{x}_k| < c_1 \bar{\mathbf{R}}_{\text{pri}}^x$$

$$\bar{\mathbf{R}}_{\text{pri}}^x = \sqrt{\frac{|\mathbf{x}_0 - \mathbf{x}_1|^2}{\langle \mathbf{n}_{\mathbf{x}_1}, \mathbf{d}_{\mathbf{x}_1 \mathbf{x}_0} \rangle / (4\pi)}}$$

进一步假设，在半径  $\sqrt{(c_2) / (\hat{p}(\mathbf{x})_{(k-1)}(\omega_{(k-1)}) G(\mathbf{x}_{(k-1)} \rightarrow \mathbf{x}_{(k)}))}$  的足迹内，相对密度变化被  $\varepsilon$  限制，则式 (6a) 的充分条件为：

$$[\mathbf{p}_{k-1}^x(\omega_{k-1}) G(\mathbf{x}_{k-1} \rightarrow \mathbf{x}_k)]^{-1} > \frac{c_1^2}{c_2} (\bar{\mathbf{R}}_{\text{pri}}^x)^2$$

该射线足迹阈值会避开由光泽 BSDF

或几何奇异性造成的密度峰值附近重连接。实践中把常数合并成式 (5) 中的单一参数  $c$ ； $c$  越大，重连接越保守，也就是越倾向于推迟重连接。

逆射线足迹阈值。射线足迹能够约束  $\mathbf{x}_k$  处的面积密度变化，却无法捕获因改变出射方向  $-\omega_{\{k-1\}}$  而导致的 BSDF 采样 PDF  $\hat{p}(\mathbf{x})_k(\omega_k)$  变化；对低粗糙度的光泽材质，这种变化可能很大。

因此我们定义逆射线足迹  $(\hat{p}(\mathbf{x})_k(\omega_k) G(\mathbf{x}_k \rightarrow \mathbf{x}_{\{k-1\}}))^{-1}$ 。假设光泽材质的 BSDF PDF 近似互易<sup>(5)</sup>，就可以把它解释为反向追踪射线（仿佛从光源追踪路径）时每个样本所代表的面积。在与上文相同的平滑性假设下，并对远距离重连接采用  $G(\mathbf{x}_k \rightarrow \mathbf{x}_{\{k-1\}}) \approx G(\mathbf{x}_k \rightarrow \mathbf{y}_{\{k-1\}})$ ，式 (6b) 的一个充分条件是：

$$[\mathbf{p}_k^x(\omega_k) G(\mathbf{x}_k \rightarrow \mathbf{x}_{k-1})]^{-1} > \frac{c_1^2}{c_2} (\bar{\mathbf{R}}_{\text{pri}}^x)^2$$

为简单起见，我们让两个阈值复用同一参数  $c$ ，从而得到式 (5) 的组合测试。这样无需在  $\mathbf{x}_k$  强制粗糙度阈值，也能够安全地重连接到远处的光泽表面<sup>(6)</sup>。

<sup>(5)</sup> 假设  $\hat{p}(\mathbf{x})_k(\omega_k) = p(\omega_k | \mathbf{x}_k, -\omega_{\{k-1\}}) \approx p(-\omega_{\{k-1\}} | \mathbf{x}_k, \omega_k)$ ；对微表面光泽材质的 NDF 采样，这一关系精确成立，对 VNDF 采样 [Heitz 2018] 则近似成立。<sup>(6)</sup> 若  $\mathbf{x}_k$  为漫反射或发光顶点，重连接不会影响  $\hat{p}(\mathbf{x})_k(\omega_k)$ ，因此跳过逆射线足迹测试。

## 4.2 单顶点粗糙度阈值

我们在  $\mathbf{x}_{\{k-1\}}$  处保留粗糙度阈值，以防视差、曲率或极低粗糙度让基于足迹的界限不可靠。否则就需要过大的几何界限或足迹容差。

粗糙度阈值还处理了重连接到环境光的情况：此时  $\Delta \mathbf{x}_k$

无界，角密度可能发生尖锐变化。有了这一保护，我们可以使用在典型场景中表现良好的更紧足迹参数  $c$ 。对于非参数化材质，补充材料讨论了把 BSDF 采样 PDF 作为粗糙度代理的方案。

## 5 使用重复图降低相关性

ReSTIR 稳定性的最大挑战之一是样本相关性。样本相关性的主要来源包括：

- 初始采样产生的低概率、高能量 firefly（萤火虫样本）；
- 不完美的移位映射把样本人为移入高能量 firefly。

这些 firefly 会通过时空复用扩散到邻近像素，形成相关性团块（例如圆盘或条纹），有时覆盖许多像素并持续多帧。糟糕的参数会加剧视觉伪影，例如空间复用半径过小。

以往工作通过部分复用路径、同时保持前缀独立 [Kettunen et al. 2023]，或突变样本以减轻样本贫化 [Sawhney et al. 2024]，来对抗相关性。但这些方法成本高，而且只能减少某些类型的相关性。

我们提出一种简单而有效的方案：降低  $c\_Cap$ ，本质上是自适应限制时间置信权重。动机很直接——时间样本的权重越大，潜在相关性越强。高度加权的时间复用给 firefly 更多机会在空间上传播，也使其在时间上保持更久。

我们的方案测量前一帧每个像素周围的相关性，并在高相关区域降低  $c\_Cap$ 。相关性度量只是统计一个空间邻域内与当前像素共享同一随机种子的像素数；这里“共享”意味着它们是由同一初始候选移位复制而来的样本。通过比较已经存储、用于潜在随机重放的随机种子来检测这种关系。实现步骤如下：

1. 每帧结束后，计算样本重复图。对每个像素，统计周围  $17 \times 17$  区域中与其共享随机种子的 reservoir 数量，并除以 288，得到重复分数  $D \in [0, 1]$ 。
2. 做时间重采样时，查找被使用的时间 reservoir 所对应的重复分数，即把当前像素反投影到上一帧后读取该位置的分数。
3. 用下式计算时间复用的修改后  $c\_Cap$ ：

$$c_{Cap} = \text{lerp}(c_{DefaultCap}, c_{minCap}, D^\alpha)$$

其中  $c\_DefaultCap$  是默认值（例如 Lin et al. [2022] 中的 20）， $c\_minCap$  是  $D = 1$  时使用的最小上限， $\alpha$  控制降低敏感度。 $\alpha = 1$  给出线性降低； $\alpha$  越接近 0，随  $D$  增大而降低得越快。

在测试中，我们发现  $c\_minCap = 1$ 、 $\alpha = 0.1$  效果良好。自适应  $c\_Cap$  能显著减少由采样或重采样产生的高能量样本造成的相关性伪影。

由于该方法根据具体样本调整置信权重，MIS 权重的单位分割（partition of unity）被破坏，从而引入小偏差。偏差只发生在修改  $c\_Cap$  的相关区域；本质上，方案用偏差换取相关性降低。图 5 所示的极困难场景中，平均绝对相对偏差为 3.25%。

图 2。左：对当前像素（蓝色）进行空间复用时，被选邻居（红色）的路径必须移位到当前像素；同时当前像素的路径必须移位到邻居，以计算 MIS 权重。右：蓝色像素从红色像素复用所需的移位映射，与红色像素从蓝色像素复用所需的映射相同。因此蓝色从红色复用后，红色可以免费从蓝色复用，不再支付移位成本。

图 3。左：用连续链接索引初始化图像。右：用随机置换打乱每个  $2 \times 2$  像素块，并重复  $n_\sigma$  次以达到目标标准差；每隔一次洗牌沿对角线偏移一个像素。

图 4。用相同随机数执行 BSDF 采样，为两个像素（地面上的红、蓝三角形）可视化次级命中点（红、蓝点），可以看到样本群体发生近似精确的空间移位，因此采样密度也近似移位。绿色圆圈的半径与样本足迹成正比，即与概率密度倒数成正比。在固定表面点上，更大的足迹通常意味着红、蓝两个样本群体之间的密度变化更小，因此重连接更安全。比较不同 GGX 粗糙度（a-b 与

c-d) 可见，更大的粗糙度通常允许更安全的重连接。

## 6 实现改进

除算法贡献外，我们还提出面向实现的改进，以进一步提升性能与稳健性。我们把分离的 ReSTIR 直接光和间接光 pass 合并为一个统一算法（第 6.1 节），通过 GPU 优化减少线程分歧（第 6.2 节），并采用已有技术减少色彩噪声（第 6.3 节）和去遮挡噪声（第 6.4 节）。图 1 和图 13 汇总展示了这些改进，补充材料给出更多单项消融。

### 6.1 统一直接光照与全局光照

实时渲染器常把直接光和间接光分开计算，而且往往对间接光做更激进的近似。但利用 ReSTIR，我们可以高效采样高质量间接照明。与 Lin et al. [2022] 分别运行直接光与间接光 ReSTIR pass 不同，我们用单一 reservoir 把两者合并。

思路很简单。Lin et al. [2022] 在路径树初始化时，从 BSDF 采样的顶点  $[x_{(2)}, \dots, x_n]$  发射 NEE 射线，其中  $n$  受最大反弹次数限制。初始重采样从树中选出一条路径并存入 reservoir，即  $x_{\text{bar}} = [x_{(0)}, x_{(1)}, x_{(2)}, \dots, x_d]$ ，其末端  $x_d$  通过一条 NEE/BSDF 射线连接到光源；原始设置通常要求  $d \geq 3$ （见第 2.3 节）。生成路径树时，只需从  $x_{(1)}$  再追踪一条 NEE 射线，就能处理直接光；并让统一初始重采样有机会从树中选出更短的直接光路径（ $d = 2$ ）。这样选中的路径就来自完整路径空间。

这消除了直接光和间接光两套 ReSTIR pass 的成本与存储。出乎意料的是，质量也得到提升，因为直接光现在受益于 ReSTIR PT 内置的移位映射，尤其是光泽高光。如何修改主样本空间中的 MIS 权重和源 PDF，见补充材料。

对于光源很多的场景，我们可以在生成  $x_{(1)}$  处的 NEE 样本时选择性使用 RIS。与 ReSTIR DI 一样，目标函数中排除可见性，只对选中的光源测试可见性。我们复用 Wyman 和 Panteleev [2021] 的预采样光源 tile 方案来改善缓存相干性：每帧预计算 128 个、每个包含 1024 盏灯的 tile；每个  $8 \times 8$  屏幕 tile 抽取一个光源 tile，为每个反弹生成候选。

### 6.2 通过减少分歧改善 GPU 性能

Monte Carlo 路径追踪会产生大量 GPU 分歧，因为相邻路径常穿过完全不同的几何和材质。ReSTIR PT 还因额外控制流和中间数据（例如 reservoir）进一步增加分歧。我们采用一组优化来减少代码和数据分歧，显著提高 GPU 效率。

#### 6.2.1 低层代码优化

朴素 ReSTIR PT 实现包含许多来自 reservoir 抽样和异构路径情况的分支。我们用条件移动替换大多数分支，并在保持结果等价的前提下简化计算，以减少分歧。我们还通过删除不必要字段，并对选定量执行有损压缩，把 reservoir 存储从 88 字节降到 64 字节（细节见补充材料）。

#### 6.2.2 随机重放的流压缩

在许多场景中，只有少量像素—邻居对需要随机重放，但 warp 级执行会迫使所有线程等待。我们改为对像素—邻居对并行，并用流压缩丢弃不需要重放的对。这减少了 warp 分歧和活跃 warp 数量，带来显著加速。

### 6.2.3 强制 NEE 光源重连接

随机重放若以 NEE 采样的光源顶点结束，会产生其他路径类型无需承担的昂贵光源采样。由于重放的随机数通常会选择同一光源（例如使用基于功率的采样），如果尚未找到更早的重连接，我们就强制重连接到这些顶点。这样可以从随机重放中删除光源采样，提升性能。潜在方差增加由路径 MIS 权重缓解，因为这些情况通常发生在光泽表面，而路径 MIS 已经会降低其权重。

### 6.2.4 俄罗斯轮盘赌

初始重采样往往是最昂贵阶段，因为路径很长且分歧严重。我们在初始采样时使用俄罗斯轮盘赌来降低平均路径长度，但在随机重放中移除它，以免复用时杀死有效路径。这相当于从路径参数化中移除轮盘赌维度，并在初始路径采样时施加外部轮盘赌，同时修改主样本空间中的采样 PDF（见补充材料）。初始样本的噪声会略有增加，但时空复用大会抑制其影响，而且移位映射中由轮盘赌失败造成的路径失效被完全避免。

## 6.3 降低色彩噪声

ReSTIR 天生存在色彩噪声，因为重采样针对的是标量目标函数  $p_{\text{hat}}$ ，而被积函数  $F(y)$  是 RGB 向量。因此，GRIS 主要按亮度采样，色度没有得到良好的重要性采样。

以往工作 [Kettunen et al. 2023; Lin et al. 2022]

指出，可以通过对随机索引选择做边缘化来改善估计  $F(Y)W_Y$ 。在 ReSTIR PT

中，这几乎没有额外成本：由于  $p_{\text{hat}} = |F|$ ， $F(Y_i)$

已在空间复用期间计算。我们累积向量重采样权重：

$$w_i = m_i(Y_i) F(Y_i) W_{x_i} \left| \frac{\partial T}{\partial x_i} \right|$$

并在着色时使用  $\sum_i w_i$ 。空间邻居通常包含不相关的色度噪声<sup>(7)</sup>，因而空间复用会自然地把它平均掉。这把重采样与着色解耦：标量权重驱动未来重采样，向量权重用于着色。与直接光中类似的技术 [Wyman and Panteleev 2021] 相比，本方法不产生额外计算。

<sup>(7)</sup> 尽管时空复用也会产生空间相关的色彩噪声，但在新帧中，这种相关性通常不发生在随机抽取的空间邻居之间。

## 6.4 用双运动向量降低去遮挡噪声

去遮挡会在 ReSTIR 中造成严重噪声，因为新可见表面没有任何时间历史。双运动向量 [Zeng et al. 2021] 通过使用另一种运动向量重投影像素来处理这一问题；这种运动向量假设遮挡物与被遮挡物之间具有一致的相对运动。

我们把它直接应用到 ReSTIR 的时间重采样中，并观察到去遮挡噪声显著降低。以往工作通过存储入射辐射场来避免复制一粘贴伪影，但在 ReSTIR PT 中不会出现这个问题：无偏路径重采样阻止了图案克隆。剩余的相关噪声较轻，还可以用我们的去相关策略（第 5 节）进一步降低。

## 7 评估

评估平台是一台配备 NVIDIA RTX 5880 Ada 显卡和 AMD Ryzen Threadripper PRO 3975WX 32 核 CPU 的 PC。我们使用 Falcor [Benty et al. 2020] 实时渲染框架，并从 Lin et al. [2022] 的原始 ReSTIR PT 源代码开始优化。所有图像以  $1920 \times 1080$  渲染。图像误差使用 HDR 版本的 FLIP [Andersson et al. 2021] 度量，因为它与翻转比较图像时的感知差异高度一致。

我们沿用 ReSTIR PT 的默认时间和空间参数：时间重采样  $c\_Cap = 20$ ，空间复用在 30 像素半径内使用 3 个随机邻居。

对于配对空间复用，我们计算 3

张配对纹理，使其高斯分布具有与空间复用相同的平均样本径向距离。标准差为  $\sigma$

的各向同性高斯分布的平均样本距离是  $\sigma \sqrt{(\pi/2)}$ ，半径为  $R$  的均匀圆盘的平均样本距离是  $2R/3$ 。因此我们提出选择

$$\sigma = \sqrt{\frac{8}{9\pi}} R$$

以匹配此前工作中经验选择的  $R$ 。默认  $R = 30$  时，得到  $\sigma =$

16.0。由于把空间复用拆为两步，配对空间复用并不能完全减半成本：预 pass

把每条路径移位到所有配对邻居，第二 pass 再执行重采样。

我们使用每像素 1 spp 的路径追踪生成初始样本，即每个像素一棵路径树。对于 RIS 的 NEE 样本（第 6.1 节），遵循 Wyman 和 Panteleev [2021]，从光源 tile 中抽取 32 个光源样本作为主命中点的 NEE 候选。在更深的反弹处，按逆平方衰减计划减少 NEE 光源候选数：反弹索引为  $B$  时分配  $32/B^2$  个样本，并将其限制为至少 1 个。

### 7.1 性能

表 1 展示了各项技术的性能；每一行都在 Lin et al. [2022] 的公开源代码基线上新增一个特性或优化。我们先测量成本削减技术带来的加速：在四个测试场景上的平均加速为  $2.74\times$ 。这些场景覆盖不同的几何与材质复杂度，单场景结果见补充材料。

为了更深入了解低层 GPU 优化的影响，我们用 Nsight Graphics 对 Opera House 进行了剖析。第 6.2.1 – 6.2.3 节优化降低了线程分歧并提高 GPU 计算效率：SM warp 占用率从 22.4% 提高到 31.1%，每个 warp 的活跃线程数从 15.3 提高到 19.9，warp 延迟从 347k 周期降低到 241k，且没有改变采样器行为。再应用俄罗斯轮盘赌（第 6.2.4 节）后，这些指标进一步变为 34.9%、20.6 和 82k 周期。

虚线下方展示第 4、5、6 节技术带来的额外成本。新阈值反映了场景无关重连接判据的成本，它改善了移位映射质量。“全部改进”行应用了其他所有技术（去相关、色彩噪声和去遮挡噪声降低）。这些技术相对于最快版本使平均成本增加 19%。即使包含质量改进，我们仍比 Lin et al. [2022] 快  $2.30\times$ 。补充材料报告了更好的分辨率扩展性。

存储。本方法还通过两项变化降低相对基线的存储：压缩 ReSTIR PT reservoir，并统一直接光与间接光 reservoir。由于每个 ReSTIR pass 都需要两套 reservoir 支持时间复用，这些变化把每像素存储从基线的  $2 \times (88 + 16)$  字节（其中 ReSTIR DI reservoir 为 16 字节）降至  $2 \times 64$  字节。在  $1920 \times 1080$  分辨率下，内存消耗由 431 MB 降至 265 MB。

表 1。四个复杂度不同场景（Veatch Ajar、Carousel、Opera House、Bathroom）的平均帧和 pass 成本，单位为毫秒。虚线下方的方法会引入额外成本。

| 方法                    | 总帧    | 初始采样  | 时间复用 | 空间复用  | ReSTIR DI 及其他 |
|-----------------------|-------|-------|------|-------|---------------|
| 基线                    | 35.73 | 10.59 | 5.30 | 14.79 | 5.05          |
| + 代码微优化（6.2.1）        | 32.98 | 10.70 | 4.16 | 13.06 | 5.07          |
| + 强制 NEE 重连接（6.2.3）   | 29.75 | 11.44 | 3.40 | 9.73  | 5.19          |
| + 重放压缩（6.2.2）         | 26.81 | 11.79 | 2.66 | 6.99  | 5.37          |
| + 配对空间复用（第 3 节）       | 25.02 | 12.56 | 2.80 | 4.11  | 5.55          |
| + 俄罗斯轮盘赌（6.2.4）       | 16.52 | 5.21  | 2.24 | 3.83  | 5.24          |
| + 统一 DI 与 GI（6.1）     | 13.04 | 6.47  | 2.14 | 3.43  | 1.00          |
| + 新阈值（第 4 节）          | 14.51 | 6.68  | 2.92 | 3.60  | 1.31          |
| + 全部改进（第 5、6.3、6.4 节） | 15.53 | 6.77  | 3.20 | 3.73  | 1.83          |

## 7.2 消融研究

我们在这里更仔细研究配对空间复用（第 3 节）、新重连接判据（第 4 节）和去相关技术（第 5 节）。第 6 节技术的独立研究见补充材料。

**配对空间复用评估。** 我们把配对纹理编码成双通道可平铺图像，每个像素存储整数偏移  $(\Delta x, \Delta y) \in [-127, 127]^2$ （平铺时取模）。图 7a 可视化了  $254 \times 254$  配对纹理。在图 6 中，我们通过把每个像素与配对邻居交换来验证纹理：交换一次得到带高斯噪声的模糊，第二次交换恢复原图。

图 8 比较了我们的配对空间复用与传统的均匀圆盘采样，圆盘半径为  $R = 5, 10, 20, 30$ ；高斯核选择与之具有相同平均样本距离的参数。配对复用通过把移位映射成本减半，平均将 ReSTIR 空间复用加速  $1.63\times$ ，同时只引入少量额外开销。它还降低了 FLIP 误差，可能是因为高斯分布更集中于中心附近（见图 7b），提高了选中兼容邻居的概率。

**新重连接判据评估。** 我们全面评估了新判据。单顶点粗糙度阈值使用 ReSTIR PT 的默认  $\alpha = 0.2$ 。对于双足迹阈值，跨越大量场景的经验结果表明  $c = 0.02$ （式（5））接近最优；不同  $c$  值的消融结果见补充材料。

图 10、11、12 比较了我们的判据与 Lin et al. [2022] 的重连接规则。后者使用世界空间距离阈值和双顶点粗糙度测试；我们把距离阈值设置为场景最短尺寸的 2%，这与以往工作的典型设置相符。在不同观察距离、材质粗糙度和光照条件下，我们的阈值持续提供更高质量、更稳健的重采样。

我们的射线足迹阈值类似 Bekaert et al. [2003] 与 Müller et al. [2021] 的路径足迹判据。然而，我们发现仅使用路径足迹往往无法排除不可连接路径，因为它没有考虑重连接顶点处的材质属性。更多比较见补充材料。

**基于重复图的去相关消融。** 图 9 在 Tower Bridge 场景中把我们的重复图相关性降低方法与 RTXDI SDK [NVIDIA 2021] 的 boiling filter 比较。该场景由于初始样本质量差而具有强相关（未过滤局部图可见）。两种方法的参数分别代表弱、中（默认）和强去相关。FLIP 误差增加，反映了方法引入的变暗偏差。

RTXDI boiling filter 会计算每个 warp 像素的平均重采样权重  $w_{\text{bar}}$ ，并清除满足  $w_j > a w_{\text{bar}}$  的 reservoir，其中  $a = -9 + 10/s$ ，强度因子  $s \in (0, 1]$  控制阈值。值得注意的是，RTXDI boiling filter 为去除大多数伪影会造成显著能量损失。

### 7.3 总体质量评估

图 1 和图 13 展示了增强版 ReSTIR PT 的总体性能和质量改进。与 Lin et al. [2022] 相比，增强版减少了相关性伪影、色彩噪声和去遮挡噪声；借助新的重连接判据（例如图 1 玻璃内部的表面）以及直接光与间接光统一，它还拥有更好的质量，同时显著更快，达到相对 Lin et al. [2022] 的  $2.08 \times - 3.05 \times$  加速。

### 7.4 偏差与收敛

我们的去相关技术（第 5 节）会引入偏差；关闭它即可恢复无偏性，同时保留 ReSTIR PT Enhanced 的其他收益（见图 14 和补充材料末尾的更多比较）。实践中，这种偏差通常相对于噪声水平很小。如图 15 所示，在与实时渲染相关的时间范围内，带偏差与无偏版本在 MSE 和 FLIP 下的收敛曲线几乎重合。

默认有偏版本在 Kitchen 场景中因相关性更严重而产生更大偏差。它在初始阶段甚至有更低 MSE，因为阻止了异常值扩散；然而，随着累积时间变长，偏差逐渐显现，收敛曲线变平。在相关性较弱的典型场景 Watercolor 中，曲线变平得更慢，整体偏差水平也更低。总体而言，对于实时图像质量，我们更偏好默认的、带去相关的有偏版本。如果需要无噪声无偏图像，通常更高效的办法是关闭时间复用后进行累积 [Lin et al. 2022]。

图 5。在 Kitchen 场景评估我们的去重方法。相机沿地面运动会因为复用次优时间邻居而引入大量相关性。我们计算重复图（d、e），统计每个  $17 \times 17$  邻域中的重复样本（黑色到红色表示可视化中的 0 - 20% 重复度），并用它自适应降低  $c_{\text{Cap}}$ 。这会引入一些偏差，表现为能量损失；图（b）的平均绝对相对偏差为 3.25%。图（f）逐像素显示偏差，更光泽的表面偏差更大。

图 6。我们的配对纹理支持可逆的随机高斯“模糊”。交换两次会恢复原图；示例使用  $\sigma = 16.0$  的配对纹理。图 7。可视化  $\sigma = 16.0$ ，它与  $R = 30$  均匀圆盘采样具有相同平均样本距离。图 8。在 Opera House 中将配对空间复用（上）与均匀圆盘的传统随机空间复用（下）比较。每列选择与半径  $R$  的均匀圆盘具有相同平均样本距离的  $\sigma$ 。图 9。在 Tower Bridge 中比较基于重复图的去相关（上）和 RTXDI boiling filter（下）。图 10。新重连接阈值能适应不同观察距离，在 Kitchen 中提高一致性；基线中适合近景的阈值在远景表现不佳。图 11。Lin et al. [2022] 在 San Miguel 中展示的失败案例：混合移位难以从远处窗户上的近 delta 远距离高光（灯的反射）采样焦散；新阈值按距离有效调整“粗糙度”，使得连接到窗户成为可能。图 12。在 Veach Ajar 这类漫反射场景中，两种判据表现相近；在粗糙度 0.3 的金属墙上，基线噪声明显更多，而新阈值会自动扩大重连接距离，使噪声更一致。图 13。在 Watercolor、ZeroDay、Crown 场景比较 Lin et al. [2022] 与本文增强。得益于主命中点上更好的 MIS 和更好的重连接阈值，光泽表面采样明显改善，同时色彩、去遮挡噪声和相关性伪影减少。图 14。不使用去相关时，Watercolor 在相机向上运动期间会出现更多相关性伪影，包括灯上的噪声团块以及去遮挡区域的相关明暗轨迹。对 1024 次独立运行取平均后，默认版本显示出系统性误差（来自偏差）。图 15。Watercolor（图 13、14）和 Kitchen（图 5）的收敛曲线，比较基线 ReSTIR PT、无去相关版本和默认去相关版本。每个场景和方法用不同随机种子运行同一相机动画 1024 次，并在相机运动期间捕获同一视图后取平均。MSE 图以迭代次数为横轴；FLIP 图把迭代数据映射到捕获帧的累计渲染时间。FLIP 对 firefly

和相关性伪影不那么敏感，但仍会感知区域亮度差异。

## 8 结论与未来工作

我们提出一组增强 ReSTIR PT 的新思路，全面改善性能和稳健性。优化范围从低层 GPU 代码改进到更高层算法变化，最高可带来  $3\times$  加速。通过更好的移位映射、降低相关性以及减少色彩和去遮挡噪声，我们提高了稳健性并持续改善视觉质量。

多项贡献可以推广到其他复用算法：配对空间复用、基于足迹的重连接阈值，以及通过重复图控制时间历史。我们还发现，把直接光和间接光一起采样的统一 ReSTIR 同时提升速度与质量。

尽管有这些进展，ReSTIR PT 仍面临开放挑战，值得未来研究。高频特征在运动期间仍对时间噪声敏感；总体质量还受初始采样有效性的限制，尤其是焦散等低概率光传输效应。近期工作如 Area ReSTIR [Zhang et al. 2024] 已部分处理这些问题，因此可以探索在共享框架内，从 ReSTIR PT Enhanced 平滑过渡到增强 Area ReSTIR。新一代 GPU 架构上也仍有进一步算法与硬件感知优化的空间。

## 致谢

感谢 Miika Aittala 就配对复用纹理提供有益讨论，感谢 Aaron Lefohn 提供总体支持，也感谢匿名审稿人的建设性意见。

## 参考文献（中文释义）

- Andersson, Nilsson, Shirley, Akenine-Moeller. 2021. Visualizing errors in rendered high dynamic range images (可视化渲染 HDR 图像中的误差)。
- Bauszat, Petitjean, Eisemann. 2017. Gradient-domain path reusing (梯度域路径复用)。
- Bekaert, Sbert, Halton. 2002. Accelerating Path Tracing by Re-Using Paths (通过复用路径加速路径追踪)。
- Bekaert, Slusallek, Cools, Havran, Seidel. 2003. A custom designed density estimation method for light transport (面向光传输的定制密度估计)。
- Benty et al. 2020. The Falcor Rendering Framework (Falcor 渲染框架)。
- Bitterli et al. 2020. Spatiotemporal reservoir resampling for real-time ray tracing with dynamic direct lighting (动态直接光照实时光追的时空 reservoir 重采样)。
- Chao. 1982. A general purpose unequal probability sampling plan (通用不等概率抽样方案)。
- Halen et al. 2021. Global Illumination Based on Surfels (基于 surfel 的全局光照)。
- Heitz. 2018. Sampling the GGX distribution of visible normals (可见法线 GGX 分布采样)。
- Kettunen et al. 2015. Gradient-domain path tracing (梯度域路径追踪)。
- Kettunen et al. 2023. Conditional resampled importance sampling and ReSTIR (条件重采样重要性采样与 ReSTIR)。
- Lin et al. 2022. Generalized Resampled Importance Sampling: Foundations of ReSTIR (广义重采样重要性采样：ReSTIR 基础)。

- Majercik et al. 2019. Dynamic Diffuse Global Illumination with Ray-Traced Irradiance Fields (带光追辐照度场的动态漫反射全局光照) .
- Müller et al. 2021. Real-time neural radiance caching for path tracing (路径追踪实时神经辐射缓存) .
- NVIDIA. 2020. NVIDIA Real-Time Denoiser Delivers Best-in-Class Denoising in Ubisoft' s Watch Dogs Legion (NVIDIA 实时去噪器) .
- NVIDIA. 2021. RTXDI SDK - Light Resampling In Practice (RTXDI SDK: 光重采样实践) .
- NVIDIA. 2025. DLSS 4: Transforming Real-Time Graphics with AI (DLSS 4 技术报告) .
- Ouyang et al. 2021. ReSTIR GI: Path Resampling for Real-Time Path Tracing (ReSTIR GI: 实时路径追踪的路径重采样) .
- Sawhney et al. 2024. Decorrelating ReSTIR Samplers via MCMC Mutations (通过 MCMC 突变解相关 ReSTIR 采样器) .
- Schied et al. 2017. Spatiotemporal Variance-Guided Filtering (时空方差引导滤波) .
- Talbot, Cline, Egbert. 2005. Importance Resampling for Global Illumination (全局光照重要性重采样) .
- Wright, Narkowicz, Kelly. 2022. Lumen: Real-time Global Illumination in Unreal Engine 5 (UE5 实时全局光照 Lumen) .
- Wyman, Panteleev. 2021. Rearchitecting Spatiotemporal Resampling for Production (面向产品化重构时空重采样) .
- Zeng et al. 2021. Temporally Reliable Motion Vectors for Real-time Ray Tracing (实时光追的时间可靠运动向量) .
- Zhang et al. 2024. Area ReSTIR: Resampling for Real-Time Defocus and Antialiasing (Area ReSTIR: 实时散焦与抗锯齿重采样) .